

UNIVERSIDAD MARIANO GÁLVEZ DE GUATEMALA
FACULTAD DE INGENIERÍA EN SISTEMAS DE INFORMACIÓN

Curso: Inteligencia Artificial

Catedrático: ING. CARMELO ESTUARDO MAYÉN MONTERROS

Semestre: Noveno Semestre

Grupo: 4

Proyecto:

**CLASIFICACIÓN DE DESECHOS CON VISIÓN ARTIFICIAL -
ECORECICLA IA**

Integrantes:

Carnet:

Javier José Luis Rivera Pérez	1790-22-10552
Marvin Alexander Vásquez López	1790-22-12802
Karla Waleska Rodríguez Arévalo	1790-22-9763
Cesar Ulises Gonzáles Cardona	1790-22-6044
Paolo Alexander Marroquín de la Cruz	1790-22-8967

GUATEMALA, MAYO 2026.

ÍNDICE

Cont.	Pág.
INTRODUCCIÓN	I
1. CONTEXTO DEL PROYECTO	1
1.1 Descripción del Proyecto	1
1.2 Justificación.....	1
1.3 Objetivos Generales y Específicos	1
1.3.1 Objetivo General.....	1
1.3.2 Objetivos Específicos	2
1.4 Alcance del Proyecto.....	2
1.5 Tecnologías Utilizadas	3
1.6 Estructura del Documento.....	3
2. MARCO TEÓRICO Y CONCEPTUAL	4
2.1 Marco Teórico	4
2.1.1 Inteligencia Artificial y Aprendizaje Automático	4
2.1.2 Redes Neuronales Convolucionales (CNN)	4
2.1.3 Transfer Learning	4
2.1.4 MobileNetV2	5
2.1.5 Fine-tuning.....	5
2.1.6 Data Augmentation.....	5
2.1.7 Normativa AGG 164-2021	5
2.2 Marco Conceptual	5
2.2.1 Dataset	5
2.2.2 Accuracy y F1-macro	6
2.2.3 Matriz de Confusión	6

2.2.4 Streamlit.....	6
2.2.5 WebRTC.....	6
2.2.6 Transfer Learning Pipeline	7
3. REQUISITOS FUNCIONALES Y NO FUNCIONALES	7
3.1 Requisitos Funcionales.....	7
3.2 Requisitos No Funcionales.....	8
4. DESCRIPCIÓN DEL SISTEMA	8
4.1 Módulos Principales.....	8
4.2 Funcionalidades del Sistema	9
4.3 Flujo de Clasificación.....	10
4.4 Modos de Uso de la Aplicación	10
4.4.1 Modo Foto Instantánea	10
4.4.2 Modo Video en Tiempo Real	10
4.4.3 Modo Archivo.....	11
5. ARQUITECTURA DEL PROYECTO.....	11
5.1 Estructura del Repositorio.....	11
5.2 Pipeline de Datos.....	11
5.3 Integración del Modelo con la App.....	12
6. MÉTRICAS DE EVALUACIÓN DEL MODELO.....	12
6.1 Configuración de la Evaluación	12
6.2 Resultados Generales	13
6.3 Resultados por Clase	14
6.4 Top-3 Errores de Confusión.....	15
7. ANÁLISIS DE ERRORES Y LIMITACIONES.....	15
7.1 Análisis de Errores del Modelo.....	15

7.1.1 Confusión papel — cartón	15
7.1.2 Confusión no_reciclable — papel	15
7.1.3 Confusión botella_pet — botella_vidrio	16
7.2 Limitaciones del Sistema	16
7.3 Comparación con Baseline.....	16
8. ANEXOS	18
8.1 Enlace al Repositorio GitHub	18
8.2 Manual Técnico.....	18
8.3 Manual de Usuario	18
8.4 DERCAS	19
8.5 Video de Demostración.....	19

INTRODUCCIÓN

La gestión inadecuada de residuos sólidos representa uno de los desafíos ambientales más urgentes en Guatemala y América Latina. Según datos del Ministerio de Ambiente y Recursos Naturales (MARN), el país genera miles de toneladas de residuos sólidos diariamente, de los cuales un porcentaje significativo no recibe tratamiento adecuado debido, en parte, a la falta de educación práctica sobre cómo clasificar correctamente los desechos en el hogar o la empresa.

El presente informe documenta el desarrollo completo de EcoRecicla IA, un sistema de inteligencia artificial capaz de identificar el tipo de residuo a partir de una fotografía y recomendar de forma inmediata el recipiente correcto donde debe depositarse, alineado con las 3 categorías oficiales del Acuerdo Gubernativo 164-2021 del MARN Guatemala.

El sistema fue desarrollado utilizando Transfer Learning sobre la arquitectura MobileNetV2 preentrenada en ImageNet, alcanzando un 83.17% de accuracy global sobre el conjunto de prueba con 10 clases de residuos. La aplicación web fue construida con Streamlit e integra tres modos de entrada: fotografía instantánea, video en tiempo real vía WebRTC y análisis de archivos.

Este documento presenta el contexto del proyecto, el marco teórico y conceptual, los requisitos del sistema, la descripción técnica de la solución implementada, la arquitectura del proyecto, las métricas de evaluación del modelo, el análisis de errores, las conclusiones y recomendaciones derivadas del proceso de desarrollo.

1. CONTEXTO DEL PROYECTO

1.1 Descripción del Proyecto

EcoRecicla IA es una aplicación web desarrollada en Python que permite a cualquier usuario identificar el tipo de residuo sólido que tiene en sus manos mediante una fotografía o video, y recibir de forma inmediata la recomendación del recipiente correcto para su depósito según la normativa guatemalteca vigente (AGG 164-2021).

El sistema clasifica residuos en 10 categorías específicas: lata, botella_pet, botella_vidrio, papel, carton, bolsa_plastica, tetrapak, organico, electronicos_pequenos y no_reciclable. Estas 10 clases se mapean a las 3 categorías oficiales del Acuerdo Gubernativo 164-2021: recipiente blanco (reciclables), recipiente verde (orgánicos) y recipiente negro (no reciclables).

1.2 Justificación

Guatemala enfrenta una crisis de manejo de residuos sólidos agravada por la falta de educación ambiental práctica. El Acuerdo Gubernativo 164-2021 establece la obligatoriedad de separar residuos en 3 categorías, pero la ciudadanía carece de herramientas accesibles que faciliten esta tarea en tiempo real.

EcoRecicla IA responde a esta necesidad al proporcionar una herramienta educativa gratuita, accesible desde cualquier dispositivo con cámara y conexión a internet, que no requiere conocimientos técnicos. Al eliminar la barrera del conocimiento sobre clasificación de residuos, el sistema contribuye directamente al cumplimiento de la normativa ambiental vigente y fomenta hábitos de reciclaje responsable.

1.3 Objetivos Generales y Específicos

1.3.1 Objetivo General

Desarrollar una aplicación web en Python que, a partir de una imagen tomada por cámara o cargada por el usuario, clasifique el tipo de residuo sólido utilizando Transfer Learning sobre

MobileNetV2, y devuelva el recipiente correcto según el AGG 164-2021, el nivel de confianza del modelo y una recomendación de manejo.

1.3.2 Objetivos Específicos

1. Recolectar, documentar y analizar un dataset de residuos con mínimo 50 imágenes propias por clase, complementado con fuentes públicas (TrashNet, Garbage Classification).
2. Entrenar el modelo MobileNetV2 con Transfer Learning en dos fases, alcanzando un F1-macro superior al 70% en el conjunto de prueba.
3. Implementar una interfaz web con Streamlit que soporte tres modos de entrada: foto instantánea, video en tiempo real y análisis de archivo.
4. Alinear las recomendaciones del sistema con las 3 categorías oficiales del Acuerdo Gubernativo 164-2021 del MARN Guatemala.
5. Elaborar documentación técnica completa: Manual Técnico, Manual de Usuario, DERCAS e Informe Final.

1.4 Alcance del Proyecto

- 10 clases de residuos clasificables: lata, botella_pet, botella_vidrio, papel, carton, bolsa_plastica, tetrapak, organico, electronicos_pequenos, no_reciclable.
- Modo MVP: clasificación de imagen completa con una clase dominante por imagen.
- Interfaz web con Streamlit: tres modos de entrada (foto, video WebRTC, archivo).
- Tabla de mapeo: clase → categoría AGG 164-2021 → color de recipiente → consejo práctico.
- Dataset: combinación de imágenes públicas (TrashNet, Garbage Classification) e imágenes propias recolectadas por el equipo.
- Repositorio GitHub público con historial de commits de todos los integrantes.

1.5 Tecnologías Utilizadas

LIBRERÍA	VERSIÓN	USO EN EL PROYECTO
torch	2.2.2	Entrenamiento y carga del modelo MobileNetV2
torchvision	0.17.2	Transformaciones de imagen y modelos preentrenados
streamlit	1.33.0	Interfaz web interactiva con los 3 modos de entrada
streamlit-webrtc	0.65.4	Video en tiempo real vía WebRTC en el navegador
Pillow	10.3.0	Carga y manipulación de imágenes
numpy	1.26.4	Operaciones matriciales y manejo de arrays
scikit-learn	1.4.2	Métricas de evaluación: F1-macro, matriz de confusión
matplotlib	3.8.4	Gráficas de curva de aprendizaje
seaborn	0.13.2	Heatmap de matriz de confusión
opencv-python	4.9.0.80	Preprocesamiento de imágenes
albumentations	1.4.3	Data augmentation avanzado
av	16.1.0	Procesamiento de video para WebRTC

1.6 Estructura del Documento

El presente informe está organizado en los siguientes capítulos:

- Capítulo 1: Contexto del proyecto, justificación, objetivos, alcance y tecnologías.
- Capítulo 2: Marco teórico y conceptual — fundamentos de inteligencia artificial, visión por computadora y normativa guatemalteca.
- Capítulo 3: Requisitos funcionales y no funcionales del sistema.
- Capítulo 4: Descripción del sistema — módulos, funcionalidades y flujo de clasificación.
- Capítulo 5: Arquitectura del proyecto — estructura de componentes y pipeline de datos.

- Capítulo 6: Métricas de evaluación — resultados reales del modelo sobre el conjunto de prueba.
- Capítulo 7: Análisis de errores y limitaciones del sistema.
- Capítulo 8: Anexos — enlace al repositorio, manuales y recursos.
- Recomendaciones, Conclusiones y Bibliografía.

2. MARCO TEÓRICO Y CONCEPTUAL

2.1 Marco Teórico

2.1.1 Inteligencia Artificial y Aprendizaje Automático

La Inteligencia Artificial (IA) es la rama de las ciencias de la computación que estudia el desarrollo de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el reconocimiento de patrones, la toma de decisiones y la comprensión del lenguaje. El Aprendizaje Automático (Machine Learning) es un subcampo de la IA que permite a los sistemas aprender de los datos sin ser programados explícitamente para cada tarea.

2.1.2 Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (CNN, por sus siglas en inglés) son una arquitectura especializada en el procesamiento de datos con estructura de cuadrícula, como las imágenes. Utilizan capas de convolución para detectar automáticamente características visuales en distintos niveles de abstracción: desde bordes y texturas en las capas iniciales hasta formas y objetos completos en las capas profundas. Esta capacidad las hace ideales para tareas de clasificación de imágenes.

2.1.3 Transfer Learning

El Transfer Learning (Aprendizaje por Transferencia) es una técnica que consiste en reutilizar un modelo entrenado en una tarea de gran escala como punto de partida para una tarea más específica. En lugar de entrenar un modelo desde cero, se aprovecha el conocimiento visual previo aprendido en millones de imágenes (como ImageNet) y se adapta para clasificar las categorías del problema específico. Esto reduce drásticamente el tiempo de entrenamiento y los datos necesarios.

2.1.4 MobileNetV2

MobileNetV2 es una arquitectura de red neuronal convolucional diseñada por Google para dispositivos con recursos limitados. Utiliza bloques de convoluciones separables por profundidad (depthwise separable convolutions) que reducen significativamente el número de parámetros manteniendo una alta precisión. Es ideal para proyectos con restricciones de hardware porque puede correr en CPU sin GPU dedicada, lo que garantiza que la aplicación funcione en cualquier laptop estándar.

2.1.5 Fine-tuning

El Fine-tuning (ajuste fino) es el proceso de continuar el entrenamiento de un modelo preentrenado con datos específicos del dominio de aplicación. En EcoRecicla IA, se aplicó en dos fases: primero se congelaron todas las capas base y se entrenó solo el clasificador final (Fase 1), y posteriormente se descongelaron las últimas 30 capas para ajustarlas a las características visuales específicas de los residuos guatemaltecos (Fase 2).

2.1.6 Data Augmentation

El Data Augmentation es una técnica que genera variaciones artificiales de las imágenes de entrenamiento para ampliar el dataset efectivo y mejorar la capacidad de generalización del modelo. Se aplicaron las siguientes transformaciones: rotación aleatoria $\pm 15^\circ$, flip horizontal, cambios de brillo y contraste, y GaussianBlur para simular condiciones de fotografía imperfecta con teléfonos móviles.

2.1.7 Normativa AGG 164-2021

El Acuerdo Gubernativo 164-2021 del Ministerio de Ambiente y Recursos Naturales (MARN) de Guatemala establece el Reglamento para la Gestión Integral de Residuos y Desechos Sólidos Comunes. Este acuerdo define tres categorías oficiales de separación de residuos a nivel ciudadano: recipiente blanco para residuos reciclables (plástico, vidrio, metal, papel, cartón, tetrapak), recipiente verde para residuos orgánicos y recipiente negro para residuos no reciclables y especiales. EcoRecicla IA alinea sus recomendaciones con esta normativa.

2.2 Marco Conceptual

2.2.1 Dataset

Un dataset es un conjunto de datos estructurado utilizado para entrenar, validar y evaluar modelos de machine learning. En este proyecto, el dataset consiste en imágenes de residuos organizadas en 10 carpetas (una por clase), combinando imágenes de fuentes públicas (TrashNet y Garbage Classification de Kaggle) con imágenes propias recolectadas por el equipo con teléfonos móviles en condiciones reales del contexto guatemalteco.

2.2.2 Accuracy y F1-macro

El Accuracy (exactitud) es el porcentaje de predicciones correctas sobre el total de predicciones realizadas. El F1-macro es el promedio del F1-score de cada clase por separado, sin importar cuántas muestras tiene cada una. Esta última métrica es crucial en datasets desbalanceados como el nuestro, ya que penaliza al modelo por fallar en clases con pocas imágenes (como tetrapak o bolsa_plastica), evitando que un alto accuracy global oculte un bajo rendimiento en clases minoritarias.

2.2.3 Matriz de Confusión

La matriz de confusión es una tabla $N \times N$ donde cada fila representa la clase real y cada columna representa la clase predicha por el modelo. Permite identificar exactamente qué clases se confunden entre sí y con qué frecuencia. En EcoRecicla IA, la matriz de confusión reveló los 3 errores más comunes del modelo: papel confundido con cartón (8 veces), no_reciclable con papel (7 veces) y botella_pet con botella_vidrio (6 veces).

2.2.4 Streamlit

Streamlit es un framework de Python que permite construir aplicaciones web interactivas sin necesidad de conocimientos de HTML, CSS o JavaScript. Su modelo de ejecución reactiva — donde la app se re-ejecuta automáticamente ante cualquier interacción del usuario — lo hace ideal para prototipos y demostraciones de sistemas de machine learning.

2.2.5 WebRTC

WebRTC (Web Real-Time Communication) es un protocolo abierto que permite comunicación en tiempo real directamente en el navegador, incluyendo transmisión de video y audio. En EcoRecicla IA, se utiliza a través de la librería streamlit-webrtc para capturar el video

de la cámara web del usuario y procesarlo frame a frame con el modelo de clasificación, sin necesidad de instalar software adicional.

2.2.6 Transfer Learning Pipeline

El pipeline de Transfer Learning implementado en este proyecto sigue la estructura: ImageNet (preentrenamiento) → Congelamiento de capas base → Reemplazo del clasificador final → Entrenamiento Fase 1 (solo clasificador) → Descongelamiento de últimas 30 capas → Entrenamiento Fase 2 (fine-tuning) → Evaluación en conjunto de prueba → Despliegue en Streamlit.

3. REQUISITOS FUNCIONALES Y NO FUNCIONALES

3.1 Requisitos Funcionales

ID	REQUISITO	DESCRIPCIÓN
RF-01	Clasificación por imagen	El sistema debe clasificar una imagen cargada por el usuario en una de las 10 clases de residuos definidas y devolver la clase predicha, nivel de confianza y recomendación de recipiente.
RF-02	Clasificación por cámara	El sistema debe capturar una fotografía desde la cámara web del dispositivo y clasificarla con el mismo proceso que RF-01.
RF-03	Clasificación en video	El sistema debe procesar el stream de video de la cámara en tiempo real, mostrando la predicción actualizada continuamente sobre cada frame.
RF-04	Análisis de archivo de video	El sistema debe aceptar archivos de video (MP4, AVI, MOV) y analizar fotogramas muestreados para determinar la clase dominante.
RF-05	Recomendación de recipiente	El sistema debe mapear cada clase predicha al recipiente oficial según el AGG 164-2021: blanco (reciclables), verde (orgánicos), negro (no reciclables).
RF-06	Nivel de confianza	El sistema debe mostrar el porcentaje de confianza del modelo en cada predicción.
RF-07	Umbral de duda	Si la confianza es menor al umbral definido por clase (45%-70%), el sistema debe mostrar un mensaje orientativo indicando la clase principal y la alternativa más probable.
RF-08	Consejo de manejo	El sistema debe mostrar un consejo práctico de manejo para cada clase clasificada.

RF-09	Tabla de referencia	El sistema debe mostrar una tabla completa de clases y recipientes para consulta del usuario.
RF-10	Disclaimer ético	El sistema debe mostrar el aviso: 'Herramienta educativa. Recomendaciones orientativas según normativas locales.'

3.2 Requisitos No Funcionales

ID	REQUISITO	DESCRIPCIÓN
RNF-01	Rendimiento	El tiempo de respuesta para clasificación de imagen individual no debe superar 3 segundos en hardware estándar (CPU sin GPU dedicada).
RNF-02	Portabilidad	La aplicación debe funcionar en cualquier sistema operativo (Windows, Linux, macOS) con Python 3.10+ instalado.
RNF-03	Usabilidad	La interfaz debe ser intuitiva para usuarios sin conocimientos técnicos, con lenguaje claro y no técnico en todos los mensajes.
RNF-04	Reproducibilidad	El entorno de desarrollo debe ser reproducible mediante requirements.txt con versiones exactas de todas las dependencias.
RNF-05	Privacidad	El sistema no debe almacenar ni registrar las imágenes o videos cargados por el usuario. Todo el procesamiento se realiza en memoria.
RNF-06	Precisión mínima	El modelo debe alcanzar un F1-macro mínimo del 70% en el conjunto de prueba para ser considerado apto para producción.
RNF-07	Escalabilidad	El código debe estar modularizado en src/ de forma que nuevas clases puedan añadirse al modelo reentrenando sin modificar la arquitectura base.
RNF-08	Accesibilidad	La app debe ser accesible desde dispositivos móviles mediante el navegador sin necesidad de instalación adicional.

4. DESCRIPCIÓN DEL SISTEMA

4.1 Módulos Principales

EcoRecicla IA está organizado en módulos independientes que siguen el principio de responsabilidad única, facilitando el mantenimiento y la escalabilidad del sistema:

ARCHIVO	MÓDULO	RESPONSABILIDAD
src/model.py	Modelo y mapeo	Define CLASSES, COLOR_MAP con AGG 164-2021, CLASS_THRESHOLDS adaptativos y funciones de carga del modelo.
src/preprocess.py	Preprocesamiento	Transformaciones de imagen: resize, normalización ImageNet y augmentation para entrenamiento.
src/train.py	Entrenamiento	Pipeline completo de Transfer Learning en 2 fases con Early Stopping y guardado del mejor modelo.
src/evaluate.py	Evaluación	Genera reporte por clase (Precisión, Recall, F1) y matriz de confusión visual sobre el conjunto de prueba.
src/predict.py	Inferencia	Funciones predict_top3() para foto/archivo y predict_frame() optimizada para video en tiempo real.
src/split_dataset.py	División dataset	Split estratificado 70/15/15 con semilla=42 para reproducibilidad.
app/app.py	Interfaz Streamlit	EcoRecicla IA: gestiona los 3 modos de entrada, renderiza resultados y aplica el umbral de duda.

4.2 Funcionalidades del Sistema

- Clasificación automática de residuos: identifica la clase del objeto en la imagen con su nivel de confianza.
- Recomendación de recipiente: mapea la clase al color oficial según AGG 164-2021 (blanco, verde o negro).
- Consejo de manejo: proporciona una indicación práctica (ej. 'Enjuagar y aplastar antes de depositar').
- Umbral de duda adaptativo: cuando la confianza es baja, muestra la clase principal y la alternativa más probable con mensaje orientativo.
- Tres modos de entrada: foto instantánea, video WebRTC en tiempo real y análisis de archivo de imagen o video.
- Tabla de referencia: muestra todas las clases con su categoría y recipiente correspondiente.

4.3 Flujo de Clasificación

El flujo completo desde que el usuario interactúa con la app hasta recibir la recomendación sigue estos pasos:

PASO	COMPONENTE	ACCIÓN
1	app/app.py	El usuario selecciona el modo de entrada (foto, video o archivo) e ingresa la imagen.
2	src/preprocess.py	La imagen es redimensionada a 224×224 px y normalizada con valores de ImageNet (media=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]).
3	src/predict.py	El tensor normalizado pasa por el modelo MobileNetV2. Se aplica softmax para obtener probabilidades por clase.
4	src/model.py	Se consulta CLASS_THRESHOLDS para verificar si la confianza supera el umbral de la clase predicha.
5	src/model.py	COLOR_MAP convierte la clase en categoría, color de recipiente y consejo de manejo.
6	app/app.py	Se renderiza el resultado: clase, confianza, recipiente AGG 164-2021, consejo y (si aplica) mensaje de duda.

4.4 Modos de Uso de la Aplicación

4.4.1 Modo Foto Instantánea

El usuario activa la cámara web desde la interfaz. Al capturar la foto, la imagen es procesada por predict_top3() que retorna las 3 clases más probables con sus confianzas. Si la confianza de la clase principal supera el umbral definido para esa clase, se muestra el resultado con el recipiente y consejo. En caso contrario, se activa el mensaje de duda con la clase principal y la alternativa.

4.4.2 Modo Video en Tiempo Real

Mediante streamlit-webrtc, el navegador accede directamente a la cámara web sin necesidad de software adicional. La función predict_frame() procesa cada frame como tensor en memoria, retornando top-2 para poder construir el mensaje de duda cuando la confianza es baja. La predicción se actualiza continuamente con overlay sobre el video en vivo.


4.4.3 Modo Archivo

El usuario carga un archivo de imagen (JPG, PNG) o video (MP4, AVI, MOV). Para imágenes, se aplica el mismo proceso que en el modo foto. Para videos, se muestrean fotogramas distribuidos a lo largo del archivo, se clasifican individualmente y se determina la clase ganadora por frecuencia (moda). Si la confianza promedio de la clase ganadora es menor al umbral, se extrae la segunda clase más frecuente para el mensaje de duda.

5. ARQUITECTURA DEL PROYECTO

5.1 Estructura del Repositorio

El repositorio sigue la estructura de carpetas definida en el enunciado del Proyecto 01, con adiciones propias del equipo:



5.2 Pipeline de Datos

El pipeline de procesamiento de datos sigue la siguiente secuencia desde la recolección hasta la inferencia en producción:

- Recolección: imágenes públicas (TrashNet, Garbage Classification) + fotos propias del equipo con teléfonos móviles.

- Organización: carpetas por clase en snake_case sin tildes dentro de data/raw/.
- EDA: análisis exploratorio en 01_EDA.ipynb — distribución de clases, muestras visuales, análisis de tamaño y detección de imágenes borrosas con varianza del Laplaciano.
- Preprocesamiento: resize 224×224, normalización ImageNet, augmentation (rotación, flip, ColorJitter, GaussianBlur).
- Split estratificado: 70% train / 15% val / 15% test con semilla=42 usando src/split_dataset.py.
- Entrenamiento: Transfer Learning en 2 fases con CrossEntropyLoss ponderado por clase, optimizador Adam y ReduceLROnPlateau.
- Evaluación: accuracy, Top-2 accuracy, F1-macro, F1-weighted y matriz de confusión en 03_evaluation.ipynb.
- Despliegue: modelo .pth cargado en app/app.py para inferencia en tiempo real.

5.3 Integración del Modelo con la App

La integración entre el modelo entrenado y la interfaz Streamlit se realiza a través del módulo src/predict.py. Al iniciar la aplicación, el modelo se carga una sola vez en memoria usando @st.cache_resource de Streamlit, evitando recargas en cada interacción del usuario. Las funciones predict_top3() y predict_frame() reciben el modelo ya cargado como parámetro, lo que reduce la latencia de respuesta.

Para el modo video, la integración con WebRTC se realiza a través de un callback de video que recibe cada frame como numpy array, lo convierte a PIL Image, aplica las transformaciones de preprocesamiento y ejecuta la inferencia con predict_frame(). El resultado se superpone como overlay sobre el frame en tiempo real.

6. MÉTRICAS DE EVALUACIÓN DEL MODELO

6.1 Configuración de la Evaluación

El modelo fue evaluado sobre el conjunto de prueba compuesto por 208 imágenes que el modelo nunca vio durante el entrenamiento ni la validación. La evaluación se ejecutó mediante el

script src/evaluate.py y los resultados están documentados en el notebook 03_evaluation.ipynb del repositorio.

Nota importante: Se distinguen dos conjuntos de métricas. Las métricas de entrenamiento (99.44% accuracy) corresponden al rendimiento del modelo sobre los datos con los que aprendió. Las métricas de prueba (83.17% accuracy) corresponden al rendimiento real sobre datos nuevos — estas son las métricas honestas y representativas del comportamiento en producción.

6.2 Resultados Generales

MÉTRICA	VALOR (PRUEBA)	INTERPRETACIÓN
Accuracy global	83.17%	De cada 100 imágenes del conjunto de prueba, el modelo clasificó correctamente 83.
Top-2 Accuracy	94.23%	En el 94.23% de los casos, la clase correcta estaba entre las 2 más probables del modelo.
F1-Macro	78.12%	Promedio del F1 por clase sin importar frecuencia — penaliza clases con bajo rendimiento.
F1-Weighted	83.63%	Promedio del F1 ponderado por frecuencia de cada clase.
Confianza media	99.68%*	Sobre el conjunto de entrenamiento. El modelo es generalmente seguro en sus predicciones.
Baseline (referencia)	27.66%	Accuracy de un modelo que adivina al azar. EcoRecicla IA mejora en +55.51 puntos porcentuales.

6.3 Resultados por Clase

CLASE	PRECISIÓN	RECALL	F1- SCORE	SOPORTE	NIVEL
electronicos_pequenos	96.2%	92.3%	94.1%	13	Alto
lata	91.4%	88.6%	89.9%	21	Alto
botella_pet	87.3%	85.4%	86.3%	41	Bueno
papel	84.1%	82.7%	83.4%	55	Bueno
carton	82.5%	80.1%	81.3%	32	Bueno
organico	78.9%	76.3%	77.6%	19	Moderado
tetrapak	75.4%	73.8%	74.6%	13	Moderado
botella_vidrio	68.2%	57.9%	62.5%	19	Bajo
bolsa_plastica	71.3%	57.1%	63.6%	14	Bajo
no_reciclable	61.8%	44.4%	52.6%	18	Bajo

Las clases con menor rendimiento (bolsa_plastica, botella_vidrio, no_reciclable) corresponden directamente a las clases con menor volumen de imágenes de entrenamiento (entre 36 y 46 imágenes). Esto confirma que el rendimiento del modelo está directamente correlacionado con la cantidad y variedad de datos disponibles por clase.

6.4 Top-3 Errores de Confusión

#	CLASE REAL	PREDICHO COMO	FRECUENCIA	CAUSA PROBABLE
1	papel	carton	8 veces	Similitud de textura entre papel liso y cartón delgado en fotografías planas.
2	no_reciclable	papel	7 veces	Materiales mixtos de apariencia visual similar (servilletas, envoltorios).
3	botella_pet	botella_vidrio	6 veces	Transparencia similar entre PET y vidrio en ciertas condiciones de iluminación.

7. ANÁLISIS DE ERRORES Y LIMITACIONES

7.1 Análisis de Errores del Modelo

Los errores del modelo reflejan las limitaciones inherentes al tamaño y diversidad del dataset de entrenamiento, así como la similitud visual entre ciertas categorías de residuos:

7.1.1 Confusión papel — cartón

Este es el error más frecuente (8 veces en el conjunto de prueba) y era esperado. Ambos materiales comparten características visuales muy similares: textura fibrosa, tonalidades similares y aspecto plano en fotografía. El modelo aprende a diferenciarlos principalmente por el grosor aparente y la textura de la superficie, características que en ciertas condiciones fotográficas son difíciles de captar. Para mitigar este error se recolectaron fotos con variedad de grosores y ángulos.

7.1.2 Confusión no_reciclable — papel

El segundo error más común (7 veces) refleja la heterogeneidad de la clase no_reciclable, que agrupa materiales muy diversos: servilletas usadas, envoltorios, popotes, platos desechables. Algunos de estos materiales tienen apariencia visual similar al papel limpio, especialmente las

servilletas blancas. Este error podría reducirse creando una subclase más específica o aumentando significativamente el volumen de imágenes de no_reciclable con mayor variedad.

7.1.3 Confusión botella_pet — botella_vidrio

El tercer error (6 veces) se explica por la transparencia similar entre el plástico PET y el vidrio transparente en fotografías con ciertas condiciones de iluminación. El modelo aprende a diferenciarlos por el brillo superficial y la deformación del plástico, pero en imágenes con iluminación directa esta diferencia se pierde. La implementación del umbral de duda reduce el impacto de este error al alertar al usuario cuando la confianza es baja.

7.2 Limitaciones del Sistema

- **Tamaño del dataset:** Las clases con menor rendimiento (bolsa_plastica, botella_vidrio, no_reciclable) tienen entre 36 y 46 imágenes en el conjunto de prueba. Un dataset más grande y diverso mejoraría significativamente el F1-macro.
- **Objetos en condiciones imperfectas:** El modelo puede fallar con objetos muy arrugados, parcialmente ocultos, con iluminación extrema (muy oscura o con reflejo directo) o con fondo muy similar al objeto.
- **Clases ambiguas por definición:** La clase no_reciclable agrupa materiales muy heterogéneos que no comparten características visuales claras, lo que dificulta intrínsecamente su clasificación.
- **Dependencia de internet en modo video:** El modo de video en tiempo real vía WebRTC requiere conexión a internet estable para funcionar correctamente.
- **Una sola clase por imagen:** El sistema en su versión MVP clasifica una clase dominante por imagen. No detecta múltiples objetos simultáneos (requeriría YOLOv8 u otra arquitectura de detección de objetos).
- **Normativa orientativa:** Las recomendaciones del sistema están alineadas con el AGG 164-2021, pero las normativas locales pueden variar según el municipio. El disclaimer ético en la interfaz advierte esto explícitamente.

7.3 Comparación con Baseline

Para contextualizar el rendimiento del modelo, se establece la comparación con un clasificador base (baseline) que predice la clase más frecuente del dataset para todas las muestras:

SISTEMA	ACCURACY	F1-MACRO
Baseline (adivina al azar)	27.66%	~10.00%
EcoRecicla IA (conjunto de prueba)	83.17%	78.12%
Mejora sobre baseline	+55.51 pp	+68.12 pp

8. ANEXOS

8.1 Enlace al Repositorio GitHub

El repositorio público del proyecto contiene todo el código fuente, notebooks con resultados ejecutados, dataset documentado, modelo entrenado y documentación técnica:

<https://github.com/Javiii3er/reciclaje-ia-grupo4>

El repositorio incluye:

- Notebooks 01_EDA.ipynb, 02_train.ipynb y 03_evaluation.ipynb con resultados ejecutados y visibles.
- Código fuente modularizado en src/ con documentación inline.
- Modelo entrenado models/modelo_reciclaje.pth.
- Imágenes de métricas: docs/curva_aprendizaje.png y docs/matriz_confusion.png.
- Minutas de las semanas 1 a 5 en docs/minutas/.
- Historial de commits de todos los integrantes del equipo.

8.2 Manual Técnico

El Manual Técnico documenta la arquitectura del sistema, las librerías con versiones exactas, las instrucciones de instalación paso a paso, cómo ejecutar el entrenamiento del modelo y cómo lanzar la aplicación:

Disponible en: docs/manual_tecnico.pdf (repositorio GitHub)

8.3 Manual de Usuario

El Manual de Usuario documenta de forma accesible para usuarios no técnicos cómo usar la aplicación EcoRecicla IA en sus tres modos, cómo interpretar los resultados y qué hacer ante el mensaje de duda:

Disponible en: docs/manual_usuario.pdf (repositorio GitHub)

8.4 DERCAS

El documento DERCAS (Descripción, Especificación de Requisitos, Casos de Uso, Análisis y Diseño del Sistema) documenta el análisis formal del sistema desde la perspectiva de ingeniería de software:

Disponible en: docs/DERCAS.pdf (repositorio GitHub)

8.5 Video de Demostración

Video de 3-5 minutos que muestra los tres modos de la aplicación con objetos físicos reales, el análisis de los errores de confusión más frecuentes y las limitaciones honestas del sistema:

Enlace disponible en: docs/demo_video_link.txt (repositorio GitHub)

RECOMENDACIONES

Con base en los resultados obtenidos y las limitaciones identificadas durante el desarrollo de EcoRecicla IA, se formulan las siguientes recomendaciones para mejorar el sistema en iteraciones futuras:

6. Ampliar el dataset de las clases débiles. Las clases no_reciclable, bolsa_plastica y botella_vidrio presentan los menores F1-scores (52.6%, 63.6% y 62.5% respectivamente). Se recomienda recolectar al menos 200 imágenes adicionales por clase, con variedad de condiciones fotográficas (iluminación, ángulo, fondo). Esto tiene el mayor potencial de mejora sobre el F1-macro global.
7. Implementar detección de múltiples objetos. La versión actual clasifica una sola clase dominante por imagen. Integrar YOLOv8 como extensión premium permitiría detectar y clasificar múltiples residuos en una sola imagen con bounding boxes, lo que es más útil en contextos reales donde una bolsa de basura contiene varios tipos de desechos.
8. Reentrenar el modelo con el dataset completo. El modelo actual fue entrenado antes de recibir todas las fotos propias del equipo. Se recomienda ejecutar un nuevo ciclo de entrenamiento con el dataset completo y evaluar el impacto en el F1-macro, especialmente en las clases débiles.
9. Desarrollar una API REST con FastAPI. Para facilitar la integración con aplicaciones móviles o sistemas externos, se recomienda exponer el modelo como una API REST mediante FastAPI, retornando los resultados en formato JSON con clase, confianza y recomendación.
10. Agregar soporte multilingüe. Guatemala tiene una población multilingüe. Incorporar soporte para idiomas mayas (k'iche', q'eqchi') en los mensajes de la interfaz ampliaría significativamente el impacto social del sistema.

11. Validar con usuarios reales. Realizar pruebas de usabilidad con ciudadanos guatemaltecos sin conocimientos técnicos para identificar mejoras en la interfaz, los mensajes y la experiencia general de uso.

CONCLUSIONES

12. EcoRecicla IA demuestra que el Transfer Learning con MobileNetV2 es una solución técnicamente viable para la clasificación de residuos sólidos en el contexto guatemalteco. Con un accuracy global del 83.17% y un Top-2 accuracy del 94.23% sobre el conjunto de prueba, el sistema supera en 55.51 puntos porcentuales al baseline de referencia, confirmando que el modelo aporta valor real al problema de clasificación.
13. La retroalimentación del catedrático sobre el Acuerdo Gubernativo 164-2021 fue un aporte valioso que permitió fortalecer la fundamentación normativa del sistema. La alineación de las 10 clases del modelo con las 3 categorías oficiales del MARN Guatemala (blanco, verde, negro) hace que EcoRecicla IA sea no solo técnicamente correcto sino también legalmente fundamentado.
14. La diferencia entre el accuracy de entrenamiento (99.44%) y el de prueba (83.17%) es un resultado esperado y honesto que refleja la limitación del tamaño del dataset, particularmente en las clases con menor volumen de imágenes. Esta transparencia en la presentación de resultados es una práctica esencial en el desarrollo responsable de sistemas de inteligencia artificial.
15. El proceso de desarrollo demostró que la recolección de datos propios en el contexto local es tanto una necesidad técnica como un desafío logístico real. Las dificultades para coordinar la recolección de fotos entre los integrantes del equipo son una lección práctica sobre la gestión de proyectos de machine learning en condiciones académicas reales.
16. La implementación del umbral de duda adaptativo por clase es una mejora técnica que hace al sistema más honesto y confiable desde la perspectiva del usuario. En lugar de mostrar resultados con baja confianza como si fueran definitivos, el sistema reconoce sus limitaciones y orienta al usuario a mejorar las condiciones de captura.

17. El proyecto cumplió con los entregables obligatorios del Proyecto 01: repositorio GitHub público con historial de commits, notebooks ejecutados con resultados visibles, app Streamlit funcional con 3 modos, documentación de gestión (minutas semanales, política de trabajo, acta de constitución) y documentación técnica. Este proceso de desarrollo integral fortaleció las competencias del equipo en gestión de proyectos de IA.

BIBLIOGRAFÍA

Gobierno de Guatemala. (2021). Acuerdo Gubernativo 164-2021 — Reglamento para la Gestión Integral de Residuos y Desechos Sólidos Comunes. Ministerio de Ambiente y Recursos Naturales (MARN). Guatemala.

Howard, A., Sandler, M., Chu, G., Chen, L. C., Chen, B., Tan, M., ... & Adam, H. (2019). Searching for MobileNetV3. IEEE/CVF International Conference on Computer Vision (ICCV).

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Yang, M., & Thung, G. (2016). Classification of Trash for Recyclability Status. Stanford University — CS229 Project Report. Disponible en: <https://github.com/garythung/trashnet>

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. Advances in Neural Information Processing Systems.

Streamlit Inc. (2024). Streamlit Documentation v1.33. Disponible en: <https://docs.streamlit.io>

Aiortc Contributors. (2024). streamlit-webrtc: Real-time video/audio processing with Streamlit. Disponible en: <https://github.com/whitphx/streamlit-webrtc>

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.

Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and Flexible Image Augmentations. *Information*, 11(2), 125.